

评测报告

1 评测体系架构

在评测模型生成摘要的质量上，不同微调模型对应的评测脚本仅在数据预处理层进行了差异化设计。对于常规的单摘要任务，程序直接提取模型原始输出进行比对。而对于携带推理前缀的对齐方案，程序在预处理阶段引入了特异性的规则解析器，通过检索分段标记剥离前置的思维链推理及关键词段落，仅将过滤后的纯净摘要送入评测模块。




图 1: 新闻摘要提取系统评估架构

如图 1 所示，测试集中的每一条样本首先必须通过基于中英文及数字字符统计的合规度门槛。评测程序利用正则表达式抽离出模型生成文本中的所有中文字符、英文字母和数字，完全剔除了标点符号、空格及换行符。在此基础上，合规度作为一个二值乘数参与最终得分的计算，合规记为 1，不合规记为 0；当抽离出的合规字符总数不超过 60 字时，合规度判定为 1；若字符数超过 60 字，则判定为不合规，合规度置为 0，触发一票否决机制，该样本的各项核心得分与最终综合得分将一并归零。

对于通过长度合规性检测的样本，系统进一步计算事实性、语义性、词汇性三大维度的分值。为了确保各评价维度的量纲一致，所有子指标在测算时均统一转化为标准百分制进行度量：

- 事实性得分**: 采用双大模型裁判交叉验证打分。通过调用 `deepseek-v4-flash` 与 `deepseek-v4-pro` 协同评估，由两个模型直接输出 0 ~ 100 之间的整数作为事实性打分，并取两者的算术平均值作为最终分数。

- **语义性得分**：调用本地部署的双向编码表征模型 BGE-M3，强制指定第 24 层特征抽取语义分布，计算生成文本与参考答案的 BERTScore-F1 值。测算出的原始 F1 值，并转化为百分制分值。
- **词汇性得分**：分别计算字符级的 ROUGE-1、ROUGE-2 和 ROUGE-L。三者的 F-measure 原始均值在经百分制转换并限幅于 100.0 分以内后，作为最终词汇得分。

最终单条样本综合得分的计算公式为：

$$\text{综合得分} = (\text{事实性} \times 0.5 + \text{语义性} \times 0.3 + \text{词汇性} \times 0.2) \times \text{合规度}$$

进一步，系统对全部测试集样本的综合得分计算平均值，作为一种微调方案的最终评分。

2 结果分析

基于上述评测逻辑，我们在 569 条离线测试集上对未微调基座模型、基础微调模型、双任务微调模型以及思维链加 DPO 微调模型进行了定量评估。实验结果如表 1 所示。

表 1: 各微调方案在测试集上的评测结果表

方案名称	综合得分	事实性忠实度	语义性等价性	词汇精准度	长度合规度
未微调的模型	59.5	70.0	84.5	24.4	77.3%
基础微调	74.1	79.7	87.1	40.9	99.8%
双任务微调	74.2	79.3	87.5	42.1	99.5%
思维链 +DPO 微调	65.7	72.7	82.5	27.3	96.3%

从评估结果表来看，各个微调方案相较于未微调的基座模型均展现出了不同程度的性能改善。如表 1 所示，经过微调后，系统在四个评价维度上均取得了十分明显的优化。多维度评测结果分布可以参考图 2 和图 3 的直观展示。

其中，未微调的模型表现最为局限。该模型面临着严重的内容控制问题，有超过 22% 的测试样本因未能遵守命令中的“不超过 60 字”的长度硬性约束而触发零分处罚。同时，其在事实性忠实度与词汇精准度指标上也大幅度落后于经过微调的方案，这也直接印证了未微调的模型在生成摘要任务中的幻觉十分严重，进一步说明了开展模型微调的必要性。




图 2: 各方案多维能力对比柱状图

如图 2 所示, 思维链加 DPO 微调方案虽然使整体生成表现相较于微调前的有所回升, 但其事实性忠实度和语义等价性指标依然逊色于其他两种微调方案, 整体多维能力在相对雷达图中呈现出一定程度的逊色。

相比之下, 基础微调与双任务微调取得了最突出的整体效果。两者的综合得分以及四方面的得分都较为接近, 不过在更细致的对比中, 双任务微调在语义等价性和词汇精准度两个子维度上略强于基础微调, 最终以微弱的优势位列综合微调效果第一。




图 3: 各方案多维能力相对雷达图

3 误差分析

3.1 思维链加 DPO 微调方案的性能衰减机理

通过对评测程序在 DPO 方案输出上的日志监控，我们发现该方案的表现不佳并非由于偏好对齐算法失效，而是由于小模型容量瓶颈与自回归累积误差共同作用的结果。

3.1.1 参数规模局限引发的任务过载与格式失焦

本项目采用的 Qwen2.5-7B 模型其参数量级和表征容量相对有限。思维链方案要求模型在同一个自回归生成周期内，既要输出冗长的推理思维过程，又要确保最终生成的摘要文本严格符合 60 字以内的字数门槛，最后还要剔除记者及报道单位。这种极高难度的复合任务极大加剧了 7B 模型的能力拟合上限，容易导致模型在多重约束下顾此失彼。在测试生成时，模型由于格式对齐不稳定，极易发生格式标识符漏输出或错位现象。一旦评测脚本在预处理阶段未能成功匹配到切分标记，就会被迫载入全量原始推理文本。这不仅会因合规计数器超限导致合规度直接归零，在未超限样本中也会因携带千字推理冗余而极大拉低词汇匹配的字符级精度。

3.1.2 自回归解码中的错误累积效应

思维链推理模式极度依赖自回归生成的连贯性。模型在解码过程中，前期的输出会直接作为后期生成的历史上下文。如果 7B 模型在推理前期或关键词识别阶段，产生了细微的事实偏离或因果逻辑漂移，这些偏差就会随着自回归解码步骤在 Transformer 注意力网络中呈级联式累积放大，最终会严重污染尾部生成的摘要，使其在逻辑事实性检验上产生明显的劣退。

3.2 双任务微调语义与词汇精度提升机理

与基础微调方案相比，双任务微调方案在词汇精准度和语义等价性上展现出了更好的泛化表现，我们认为这主要得益于辅助任务引入的“主旨锚定与注意力正则化”效应。

双任务方案引入的“提取核心原句”辅助任务，要求模型直接定位原文中信息密度最高的主旨骨干，并在输出端强制进行无损复制。这种抽取式任务在隐式表征层起到了一种强烈的约束作用。为了拟合抽取任务，模型的概率分布被迫高度聚焦于原文中的高价值实体和主旨句。在混合微调过程中，这种强烈的注意力偏置无缝迁移至了主任务中。这有效引导模型在生成 60 字精炼摘要时，能够优先选用原文中最为核心的骨干实体，不仅有效抑制了生成过程中的语义漂移，也在字符级匹配中保留了更高比例的重合特征单字，最终在词汇和语义层面均优于常规的基础微调方案。

4 结论与改进展望

综上所述，本实验表明针对中文长文本摘要任务，双任务微调 and 基础微调能够取得比较不错的摘要提取效果。

同时，针对思维链与 DPO 方案的局限，未来改进将聚焦于两项重点：一是采用更大规模的基座模型，以缓解参数表征空间不足的问题；二是提升评测端解析器的鲁棒性与格式容错能力，防止因微小排版偏差误触发合规性的零分惩罚，在保障逻辑忠实度的同时提升生成稳定性。